

Univerzitet u Beogradu
Matematički fakultet

Predmet: Istraživanje podataka 2

Seminarski rad

Klasterovanje LinkedIn oglasa za posao

Student:
Marina Vračarić

Broj indeksa:
26/2022

Skup podataka:
LinkedIn Job Postings

Izvor:
Kaggle

Beograd, 2026.

Sadržaj

1	Tekst zadatka	3
2	Uvod	3
3	Opis podataka	4
3.1	Izvor i osnovne karakteristike skupa podataka	4
3.2	Centralna tabela <i>postings.csv</i>	6
3.2.1	Identifikatori	6
3.2.2	Informacije o radnoj poziciji	6
3.2.3	Tip rada i nivo iskustva	6
3.2.4	Plate i način prijave	7
3.3	Tabela <i>companies.csv</i>	7
3.4	Tabela <i>employee_counts.csv</i>	7
3.5	Tabela <i>benefits.csv</i>	8
3.6	Tabele <i>job_skills.csv</i> i <i>skills.csv</i>	8
3.7	Tabele <i>job_industries.csv</i> , <i>company_industries.csv</i> i <i>industries.csv</i>	9
3.8	Tabela <i>company_specialities.csv</i>	9
3.9	Tabela <i>salaries.csv</i>	9
3.10	Analiza nedostajućih vrednosti	9
3.11	Formiranje master tabele	10
4	Preprocesiranje podataka	11
4.1	Izbor atributa za klasterovanje	11
4.2	Obrada nedostajućih vrednosti	12
4.3	Transformacija kategoričkih atributa	12
4.4	Obrada tekstualnog atributa title	13
4.5	Redukcija tekstualne reprezentacije pomoću TruncatedSVD	13
4.6	Transformacija i skaliranje atributa	14
4.7	Redukcija dimenzionalnosti pomoću PCA	14
5	K-Means klasterovanje	15
5.1	Teorijske osnove algoritma	15
5.2	Eksperimentalna postavka	16
5.3	Izbor broja klastera	16
5.4	Uticaj redukcije dimenzionalnosti	17
5.5	Analiza rezultata i izbor modela	18
5.6	Vizuelizacija klastera	20
6	Agglomerative Clustering	20
6.1	Teorijske osnove algoritma	20
6.2	Eksperimentalna postavka	21
6.3	Uticaj linkage strategije	21
6.4	Analiza rezultata i izbor modela	23
6.5	Vizuelizacija klastera	24
6.6	Analiza dendrograma	24

7	DBSCAN	25
7.1	Teorijske osnove algoritma	25
7.2	Eksperimentalna postavka	26
7.3	Rezultati eksperimenata	26
7.4	Vizuelizacija rezultata	27
8	Gaussian Mixture Model (GMM)	27
8.1	Teorijske osnove algoritma	27
8.2	Eksperimentalna postavka	29
8.3	Analiza rezultata i izbor modela	29
8.4	Vizuelizacija klastera	30
9	BIRCH klasterovanje	31
9.1	Teorijske osnove algoritma	31
9.2	Eksperimentalna postavka	32
9.3	Analiza rezultata i izbor modela	33
9.4	Vizuelizacija klastera	33
10	Spectral Clustering	34
10.1	Teorijske osnove algoritma	34
10.2	Eksperimentalna postavka	35
10.3	Analiza rezultata i izbor modela	35
10.4	Vizuelizacija klastera	36
11	Evaluacija i interpretacija rezultata	36
11.1	Uporedna analiza internih metrika	37
11.2	Interpretacija klastera na osnovu naziva radnih pozicija	37
11.2.1	K-Means	38
11.2.2	GMM sa četiri komponente	38
11.2.3	GMM sa devet komponenti	39
11.2.4	BIRCH	40
11.3	Analiza plata po klasterima	40
11.4	Interpretacija klastera	42
11.5	Uticaj atributa <code>title</code> na kvalitet klasterovanja	44
12	Zaključak	45

1 Tekst zadatka

Cilj ovog seminarskog rada jeste primena metoda klasterovanja nad skupom podataka koji opisuju oglase za posao objavljene na platformi LinkedIn. Skup podataka sadrži informacije o radnim pozicijama, kompanijama, platama, industrijama, traženim veštinama, benefitima i drugim karakteristikama relevantnim za tržište rada.

Zadatak obuhvata sledeće korake:

- Izvršiti preprocesiranje podataka i formirati jedinstven skup pogodan za primenu algoritama klasterovanja.
- Obraditi numeričke, kategoričke i tekstualne atribute korišćenjem odgovarajućih tehnika transformacije podataka.
- Formirati modele klasterovanja primenom najmanje pet različitih algoritama.
- Primeniti redukciju dimenzionalnosti i analizirati njen uticaj na kvalitet formiranih klastera.
- Izvršiti evaluaciju i poređenje dobijenih modela korišćenjem odgovarajućih metrika.
- Interpretirati formirane klustere kroz karakteristike oglasa za posao kao što su plate, nazivi radnih pozicija, industrije, veštine i veličina kompanija.

Seminarski rad koji se predaje sadrži:

- Tekstualni deo koji obuhvata opis problema, opis korišćenog skupa podataka, preprocesiranje podataka, primenjene algoritme i interpretaciju rezultata.
- Originalne podatke i skup podataka dobijen nakon preprocesiranja.
- Implementacije i modele korišćene tokom analize.
- Sav materijal potreban za reprodukciju eksperimenta u lokalnom okruženju.

2 Uvod

Savremene platforme za zapošljavanje generišu ogromne količine podataka o kompanijama, radnim pozicijama, potrebnim veštinama i uslovima rada. Analiza ovakvih podataka može pružiti značajan uvid u strukturu tržišta rada, identifikovati dominantne profile poslova i omogućiti bolje razumevanje odnosa između različitih karakteristika oglasa za posao.

Jedna od najpoznatijih platformi za profesionalno umrežavanje i zapošljavanje jeste LinkedIn, na kojoj se svakodnevno objavljuju hiljade oglasa za posao iz različitih industrija i geografskih regiona. Zbog velike raznovrsnosti radnih pozicija i kompanija, ovakav skup podataka predstavlja pogodan kandidat za primenu metoda istraživanja podataka.

Za razliku od klasifikacije, kod koje unapred postoje definisane klase, klasterovanje ima za cilj pronalaženje prirodnih grupa objekata na osnovu njihove međusobne sličnosti. Na taj način moguće je identifikovati grupe oglasa koje dele zajedničke karakteristike, čak i kada takve grupe nisu unapred poznate.

Glavni cilj ovog rada jeste ispitivanje da li se oglasi za posao mogu prirodno grupisati u smislene segmente tržišta rada korišćenjem tehnika nenadgledanog učenja.

U radu je analiziran skup podataka *LinkedIn Job Postings*, koji sadrži više od 120 hiljada oglasa za posao, kao i dodatne informacije o kompanijama, industrijama, benefitima i traženim veštinama. Budući da su podaci raspoređeni kroz više međusobno povezanih tabela i da sadrže numeričke, kategoričke i tekstualne atribute, bilo je neophodno sprovesti obimno preprocesiranje pre same faze klasterovanja.

Proces pripreme podataka obuhvatio je formiranje jedinstvene master tabele, obradu nedostajućih vrednosti, transformaciju kategoričkih atributa, obradu tekstualnog atributa `title` korišćenjem TF-IDF reprezentacije, kao i redukciju dimenzionalnosti primenom metode glavnih komponenti (PCA).

Nad pripremljenim skupom podataka primenjeni su sledeći algoritmi klasterovanja:

- K-Means
- Gaussian Mixture Model (GMM)
- Agglomerative Clustering
- DBSCAN
- BIRCH
- Spectral Clustering

Za svaki algoritam analizirane su različite konfiguracije broja klastera i broja PCA komponenti, dok je kvalitet dobijenih rešenja procenjivan korišćenjem Silhouette Score metrike.

Pored numeričke evaluacije, posebna pažnja posvećena je interpretaciji formiranih klastera. Analizirani su raspodela plata, najzastupljenije radne pozicije, tražene veštine, industrije i veličina kompanija kako bi se utvrdilo da li dobijeni klasteri odgovaraju intuitivnim segmentima tržišta rada.

Rad je organizovan na sledeći način. Nakon opisa korišćenog skupa podataka prikazan je proces preprocesiranja i formiranja master tabele. Zatim su predstavljene metode redukcije dimenzionalnosti i vizuelizacije podataka, nakon čega sledi detaljna analiza primenjenih algoritama klasterovanja. Na kraju su prikazani rezultati evaluacije, interpretacija formiranih klastera i zaključci istraživanja.

3 Opis podataka

3.1 Izvor i osnovne karakteristike skupa podataka

U ovom radu korišćen je skup podataka *LinkedIn Job Postings*, preuzet sa platforme Kaggle. Skup podataka sadrži informacije o oglasima za posao objavljenim na platformi LinkedIn u periodu 2023–2024. godine. Podaci obuhvataju osnovne informacije o oglasima, kompanijama koje ih objavljuju, industrijama, traženim veštinama, benefitima, platama i veličini kompanija.


Osnovna karakteristika ovog skupa jeste njegova relaciona struktura. Podaci nisu organizovani u jednoj tabeli, već u više međusobno povezanih CSV datoteka. Zbog toga je pre same primene algoritama klasterovanja bilo neophodno detaljno razumeti strukturu podataka, identifikovati ključne tabele i veze između njih, a zatim formirati jedinstvenu master tabelu pogodnu za dalju analizu.

Centralna tabela skupa podataka je *postings.csv*, u kojoj svaki red predstavlja jedan oglas za posao. Ostale tabele dopunjuju ovu tabelu informacijama o kompanijama, industrijama, veštinama, benefitima i platama.

Tabela 1: Pregled osnovnih tabela u skupu LinkedIn Job Postings

Tabela	Broj redova	Broj kolona	Opis
<i>postings.csv</i>	123849	31	Centralna tabela; sadrži osnovne informacije o oglasima za posao.
<i>companies.csv</i>	24473	10	Informacije o kompanijama koje objavljuju oglase.
<i>employee_counts.csv</i>	35787	4	Broj zaposlenih i broj pratilaca kompanija na LinkedIn-u.
<i>benefits.csv</i>	67943	3	Benefiti koji su povezani sa pojedinačnim oglasima.
<i>job_skills.csv</i>	213768	2	Veze između oglasa i traženih kategorija veština.
<i>skills.csv</i>	35	2	Šifarnik kategorija veština.
<i>job_industries.csv</i>	164808	2	Veze između oglasa i industrija.
<i>industries.csv</i>	422	2	Šifarnik industrija.
<i>company_industries.csv</i>	24375	2	Veze između kompanija i industrija u kojima posluju.
<i>company_specialities.csv</i>	169387	2	Specijalizacije kompanija.
<i>salaries.csv</i>	40785	8	Dodatne informacije o platama za deo oglasa.

Na slici 1 prikazana je relaciona struktura skupa podataka. Dijagram jasno pokazuje da se većina tabela povezuje direktno ili indirektno sa tabelom *postings.csv*. Ključne kolone za povezivanje tabela su *job_id*, koji identifikuje oglas za posao, i *company_id*, koji identifikuje kompaniju.



Slika 1: Relacije između tabela u originalnom skupu podataka LinkedIn Job Postings

3.2 Centralna tabela *postings.csv*

Tabela *postings.csv* predstavlja osnovu celokupne analize. Svaki red u ovoj tabeli odgovara jednom oglasu za posao objavljenom na LinkedIn platformi. Tabela sadrži 123849 redova i 31 atribut.

Atributi iz ove tabele mogu se podeliti u nekoliko logičkih grupa.

3.2.1 Identifikatori

U ovu grupu spadaju atributi *job_id* i *company_id*. Atribut *job_id* jedinstveno identifikuje oglas za posao i koristi se za povezivanje sa tabelama kao što su *job_skills.csv*, *benefits.csv*, *job_industries.csv* i *salaries.csv*. Atribut *company_id* omogućava povezivanje oglasa sa kompanijom iz tabele *companies.csv*.

3.2.2 Informacije o radnoj poziciji

Najvažniji atribut u ovoj grupi je *title*, koji predstavlja naziv radne pozicije. Ovaj atribut je posebno značajan jer nosi veliku količinu semantičkih informacija o samom poslu. U kasnijoj fazi rada, atribut *title* obrađen je kao tekstualni atribut korišćenjem TF-IDF reprezentacije.

Pored naziva pozicije, tabela sadrži i attribute *description* i *skills_desc*, koji daju tekstualni opis posla i potrebnih veština.

3.2.3 Tip rada i nivo iskustva

Atribut *formatted_work_type* opisuje tip zaposlenja. U skupu podataka najzastupljeniji su oglasi za puno radno vreme, dok se u manjem broju pojavljuju ugovorni poslovi, honorarni poslovi, prakse, privremeni poslovi i drugi oblici angažovanja.

Atribut *formatted_experience_level* opisuje traženi nivo iskustva kandidata. Najveći broj oglasa pripada kategorijama *Mid-Senior level* i *Entry level*, što ukazuje da skup podataka pokriva i početne i naprednije nivoe karijere.

Tabela 2: Raspodela oglasa prema nivou iskustva

Nivo iskustva	Broj oglasa
Mid-Senior level	41489
Entry level	36708
Associate	9826
Director	3746
Internship	1449
Executive	1222

3.2.4 Plate i način prijave

Tabela *postings.csv* sadrži više atributa povezanih sa platom: `min_salary`, `max_salary`, `med_salary`, `pay_period`, `currency`, `compensation_type` i `normalized_salary`. Posebno je značajan atribut `normalized_salary`, jer predstavlja pokušaj svođenja različitih oblika isplate na uporedivu vrednost.

Međutim, podaci o platama nisu dostupni za sve oglase. Oko 70% vrednosti atributa povezanih sa platom nedostaje, što je očekivano za realne podatke sa platformi za zapošljavanje, jer veliki broj poslodavaca ne objavljuje platu u oglasu.

3.3 Tabela *companies.csv*

Tabela *companies.csv* sadrži osnovne informacije o kompanijama koje objavljuju oglase. Svaka kompanija identifikovana je atributom `company_id`, koji se koristi za povezivanje sa tabelom *postings.csv*.

Najvažniji atributi iz ove tabele su:

- `name` – naziv kompanije,
- `description` – tekstualni opis kompanije,
- `company_size` – kategorija veličine kompanije,
- `country`, `state`, `city` – geografske informacije,
- `url` – LinkedIn stranica kompanije.

Za potrebe klasterovanja najznačajniji atribut iz ove tabele bio je `company_size`, jer veličina kompanije može uticati na strukturu poslova, očekivane veštine, nivo iskustva i visinu plate. Pored toga, korišćen je i atribut `country`, dok su atributi poput naziva kompanije, adrese i URL-a izostavljeni jer predstavljaju identifikacione ili opisne informacije koje nisu pogodne za direktno klasterovanje.

3.4 Tabela *employee_counts.csv*

Tabela *employee_counts.csv* sadrži informacije o broju zaposlenih i broju pratilaca kompanija na LinkedIn platformi. Atributi ove tabele su:

- `company_id`,

- `employee_count`,
- `follower_count`,
- `time_recorded`.

Pošto se za istu kompaniju može pojaviti više zapisa u različitim vremenskim trenucima, prilikom formiranja master tabele korišćen je poslednji dostupan zapis za svaku kompaniju. Na taj način je svakoj kompaniji pridružena najnovija dostupna informacija o broju zaposlenih i broju pratilaca..

3.5 Tabela *benefits.csv*

Tabela *benefits.csv* sadrži informacije o benefitima koji su povezani sa pojedinačnim oglasima za posao. Svaki red opisuje jedan benefit vezan za određeni `job_id`. Jedan oglas može imati više benefita, zbog čega se isti `job_id` može pojaviti u više redova.

Najvažniji atributi su:

- `job_id` – identifikator oglasa,
- `type` – tip benefita,
- `inferred` – oznaka da li je benefit eksplicitno naveden ili izveden iz teksta oglasa.

U skupu se pojavljuju različiti tipovi benefita, kao što su zdravstveno osiguranje, stomatološko osiguranje, penzioni plan, pomoć pri studentskom kreditu, plaćeno porodiljsko odsustvo i drugi. Za potrebe klasterovanja atribut `type` transformisan je metodom one-hot encoding, tako da je svaki tip benefita predstavljen posebnom binarnom kolonom.

3.6 Tabele *job_skills.csv* i *skills.csv*

Tabela *job_skills.csv* povezuje oglase za posao sa kategorijama veština koje su relevantne za konkretnu poziciju. Jedan oglas može biti povezan sa više kategorija veština, dok se ista kategorija veštine može pojaviti u velikom broju oglasa. Zbog toga ova tabela predstavlja vezu više-prema-više između oglasa i veština.

Tabela sadrži sledeće attribute:

- `job_id` – identifikator oglasa,
- `skill_abr` – skraćenica kategorije veštine.

Tabela *skills.csv* predstavlja šifarnik kategorija veština. Ona povezuje skraćenicu `skill_abr` sa punim nazivom kategorije `skill_name`. Ukupno postoji 35 različitih kategorija veština.

Ove tabele su veoma značajne za analizu jer tražene veštine direktno opisuju sadržaj posla. U procesu formiranja master tabele, kategorije veština transformisane su u binarne attribute korišćenjem one-hot encoding postupka. Na taj način je za svaki oglas označeno koje kategorije veština se zahtevaju.

3.7 Tabele *job_industries.csv*, *company_industries.csv* i *industries.csv*

Industrije su opisane kroz tri povezane tabele. Tabela *industries.csv* sadrži šifarnik industrija, dok tabele *job_industries.csv* i *company_industries.csv* povezuju industrije sa oglasima za posao i kompanijama. Ove informacije mogu biti značajne za razlikovanje sektora tržišta rada, jer se poslovi iz različitih industrija često razlikuju po traženim veštinama, nazivima pozicija i visini plata.

Zbog velikog broja različitih industrija, u master tabelu uključene su samo najzastupljenije kategorije. Eksperimentalno je utvrđeno da prvih 75 industrija pokriva približno 96% svih oglasa, zbog čega je ovaj broj izabran kao kompromis između informativnosti i dimenzionalnosti podataka.

3.8 Tabela *company_specialities.csv*

Tabela *company_specialities.csv* sadrži oblasti specijalizacije kompanija i predstavlja dodatni opis njihovog poslovanja. Međutim, atribut specijalizacije ima izuzetno veliku kardinalnost, sa više desetina hiljada različitih vrednosti. Njegovo uključivanje u proces klasterovanja dovelo bi do značajnog povećanja dimenzionalnosti podataka, zbog čega ova tabela nije korišćena u finalnoj reprezentaciji.

3.9 Tabela *salaries.csv*

Tabela *salaries.csv* sadrži informacije o platama povezane sa oglasima za posao, uključujući minimalnu, maksimalnu i medijalnu platu, period isplate i valutu. Iako ovi podaci predstavljaju važan izvor informacija za analizu tržišta rada, dostupni su samo za deo oglasa u skupu podataka.

Zbog velikog broja nedostajućih vrednosti, atributi povezani sa platama nisu korišćeni kao ulaz u modele klasterovanja. Umesto toga, sačuvani su za kasniju interpretaciju i evaluaciju dobijenih klastera.

3.10 Analiza nedostajućih vrednosti

Pre formiranja master tabele izvršena je analiza nedostajućih vrednosti u ključnim tabelama. Najizraženiji problem uočen je u tabeli *postings.csv*, gde pojedini atributi imaju veoma visok procenat nedostajućih vrednosti.

Tabela 3: Atributi sa najvećim procentom nedostajućih vrednosti u tabeli *postings.csv*

Atribut	Nedostajuće vrednosti (%)
closed_time	99.13
skills_desc	98.03
med_salary	94.93
remote_allowed	87.69
applies	81.17
min_salary	75.94
max_salary	75.94
normalized_salary	70.87

Kolone sa izrazito visokim procentom nedostajućih vrednosti nisu pogodne za direktno korišćenje u modelima klasterovanja. Posebno se izdvajaju atributi povezani sa zatvaranjem oglasa, detaljnim opisom veština i platama. Ipak, iako plate nisu pogodne kao ulazni atribut zbog velikog broja nedostajućih vrednosti, one su zadržane za kasniju analizu i tumačenje klastera.

Tabela *companies.csv* ima znatno bolji kvalitet podataka. Najvažniji atribut sa nedostajućim vrednostima je `company_size`, kod kojeg nedostaje približno 11.33% vrednosti. Ovak procenat je prihvatljiv, pa je atribut zadržan u daljoj analizi.

3.11 Formiranje master tabele

Nakon analize strukture podataka, izvršeno je formiranje jedinstvene master tabele. Kao osnova je korišćena tabela *postings.csv*, jer ona sadrži jedan red po oglasu za posao i predstavlja prirodnu jedinicu analize.

Proces formiranja master tabele obuhvatio je sledeće korake:

1. Polazna tabela bila je *postings.csv*, sa 123849 oglasa za posao.
2. Iz tabele *companies.csv* dodati su atributi `company_size` i `country`.
3. Iz tabele *employee_counts.csv* dodati su poslednji dostupni podaci o broju zaposlenih i broju pratilaca za svaku kompaniju.
4. Tabela *job_skills.csv* transformisana je u skup binarnih atributa koji označavaju prisustvo pojedinačnih kategorija veština.
5. Tabela *benefits.csv* transformisana je u skup binarnih atributa koji označavaju prisustvo pojedinačnih benefita.
6. Tabela *job_industries.csv* povezana je sa tabelom *industries.csv*, nakon čega su najzastupljenije industrije kodirane binarnim atributima.

Tabele u kojima jedan oglas može imati više vrednosti, kao što su *job_skills.csv*, *benefits.csv* i *job_industries.csv*, nisu mogle biti direktno spojene sa tabelom *postings.csv*, jer bi to dovelo do dupliranja redova. Zbog toga su ove tabele prvo agregirane i transformisane u binarne attribute. Na primer, za svaku kategoriju veštine formirana je posebna kolona koja ima vrednost 1 ukoliko je ta veština povezana sa oglasom, odnosno 0 u suprotnom.

Nakon povezivanja svih relevantnih tabela formirana je master tabela *master_raw.csv*. Ova tabela predstavlja osnovu za dalje preprocesiranje, redukciju dimenzionalnosti i primenu algoritama klasterovanja.

Tabela 4: Pregled formiranja master tabele

Korak	Opis
Polazna tabela	<i>postings.csv</i> ; jedan red predstavlja jedan oglas za posao.
Dodavanje podataka o kompaniji	Iz tabele <i>companies.csv</i> dodati su veličina kompanije i država.
Dodavanje broja zaposlenih	Iz tabele <i>employee_counts.csv</i> dodat je poslednji poznati broj zaposlenih i pratilaca.
Obrada veština	Kategorije veština su kodirane binarnim atributima.
Obrada benefita	Tipovi benefita su kodirani binarnim atributima.
Obrada industrija	Najzastupljenije industrije su kodirane binarnim atributima.

Na ovaj način relacioni skup podataka pretvoren je u jednu tabelu pogodnu za primenu algoritama mašinskog učenja. Time je završena faza razumevanja strukture podataka i pripremljena osnova za naredno poglavlje, u kojem je prikazano detaljno preprocesiranje podataka.

4 Preprocesiranje podataka

Polazni skup podataka ima složenu relacionu strukturu i obuhvata numeričke, kategoričke i tekstualne attribute. Zbog toga se podaci ne mogu direktno koristiti u algoritmima klasterovanja, već ih je najpre potrebno svesti na jedinstvenu, potpunu i numeričku reprezentaciju.

U ovoj fazi izvršeno je izdvajanje relevantnih atributa, obrada nedostajućih vrednosti, transformacija kategoričkih i tekstualnih obeležja, skaliranje numeričkih vrednosti i redukcija dimenzionalnosti. Time je originalni skup podataka transformisan u oblik pogodan za poređenje različitih algoritama klasterovanja.

Preprocesiranje nije posmatrano samo kao tehnički korak, već kao deo analize koji direktno utiče na kvalitet dobijenih klastera. Posebna pažnja posvećena je tome da se uklone atributi koji mogu uneti šum ili pristrasnost, dok su informacije važne za opis tržišta rada zadržane i prilagođene za dalju obradu.

4.1 Izbor atributa za klasterovanje

Pre početka klasterovanja uklonjeni su atributi koji ne nose korisne informacije za grupisanje oglasa, uključujući identifikatore (*job_id*, *company_id*), URL adrese i vremenske oznake.

Posebna pažnja posvećena je atributima povezanim sa platama i nazivu radne pozicije.

Atributi koji opisuju platu nisu uključeni u proces klasterovanja zbog veoma velikog procenta nedostajućih vrednosti. Njihovo korišćenje zahtevalo bi obimnu imputaciju, što bi moglo negativno uticati na kvalitet modela. Umesto toga, informacije o platama sačuvane su za kasniju interpretaciju i evaluaciju dobijenih klastera.

Sa druge strane, atribut *title* sadrži značajne informacije o vrsti posla, potrebnim veštinama i nivou odgovornosti. Iako njegova obrada značajno povećava dimenzionalnost

podataka, eksperimenti su pokazali da uključivanje naziva radne pozicije dovodi do formiranja smislenijih i lakše interpretabilnih klastera. Zbog toga je atribut `title` zadržan u konačnoj reprezentaciji podataka.

4.2 Obrada nedostajućih vrednosti

Nakon izbora atributa izvršena je obrada preostalih nedostajućih vrednosti. Kategorički atribut `country` dopunjen je kategorijom *Unknown*, dok su za numeričke attribute `views`, `employee_count`, `follower_count` i `company_size` nedostajuće vrednosti popunjene medijanom.

Atribut `company_size` tretiran je kao ordinalna promenljiva jer postoji prirodan odnos između njegovih kategorija i broja zaposlenih u kompaniji.

Tabela 5: Pregled obrade nedostajućih vrednosti

Atribut	Postupak obrade
<code>country</code>	Zamena nedostajućih vrednosti kategorijom <i>Unknown</i> .
<code>company_size</code>	Popunjavanje medijanom, atribut tretiran kao ordinalan.
<code>views</code>	Popunjavanje medijanom.
<code>employee_count</code>	Popunjavanje medijanom.
<code>follower_count</code>	Popunjavanje medijanom.

Nakon obrade nedostajućih vrednosti formirana je tabela *master_clean.csv* dimenzija 123849×131 .

4.3 Transformacija kategoričkih atributa

Kako algoritmi klasterovanja rade isključivo sa numeričkim podacima, kategorički atributi transformisani su primenom one-hot kodiranja. Ova metoda omogućava predstavljanje svake kategorije posebnim binarnim atributom bez uvođenja veštačkog redosleda između kategorija.

One-hot kodiranje primenjeno je nad atributima `formatted_work_type`, `application_type`, `formatted_experience_level` i `country`.

Tabela 6: Kategorički atributi transformisani one-hot kodiranjem

Atribut	Broj različitih vrednosti
<code>formatted_work_type</code>	7
<code>application_type</code>	4
<code>formatted_experience_level</code>	7
<code>country</code>	81

Nakon primene one-hot kodiranja broj atributa povećan je sa 131 na 226, pri čemu je najveći doprinos povećanju dimenzionalnosti imao atribut `country`.

4.4 Obrada tekstualnog atributa `title`

Naziv radne pozicije predstavlja jedan od najinformativnijih atributa u skupu podataka jer direktno opisuje prirodu posla i često sadrži informacije o nivou iskustva, odgovornostima i oblasti rada.

Kako tekstualni podaci ne mogu biti direktno korišćeni u algoritmima klasterovanja, nad atributom `title` primenjena je TF-IDF (*Term Frequency – Inverse Document Frequency*) transformacija. Pre transformacije izvršena je osnovna normalizacija teksta, uključujući prevođenje svih karaktera u mala slova i uklanjanje engleskih stop-reči.

Radi kontrole dimenzionalnosti broj generisanih TF-IDF atributa ograničen je na 300, dok su iz analize isključeni termini koji se pojavljuju u manje od deset oglasa. Parametri korišćene transformacije prikazani su u tabeli 7.

Tabela 7: Parametri TF-IDF transformacije atributa `title`

Parametar	Vrednost
Broj karakteristika	300
Minimalan broj pojavljivanja termina	10
Stop-reči	Engleske stop-reči
Tip tokena	Reči sastavljene od slova

Dobijena TF-IDF reprezentacija omogućila je uključivanje informacija sadržanih u nazivima radnih pozicija u proces klasterovanja. Kasnija analiza pokazala je da atribut `title` ima značajan doprinos formiranju interpretabilnih klastera, zbog čega je zadržan u konačnoj reprezentaciji podataka.

4.5 Redukcija tekstualne reprezentacije pomoću TruncatedSVD

Primenom TF-IDF transformacije nad atributom `title` dobijeno je 300 novih atributa. Iako ovakva reprezentacija sadrži značajnu količinu informacija, velika dimenzionalnost može negativno uticati na efikasnost i kvalitet klasterovanja.

Zbog toga je primenjena metoda TruncatedSVD, koja omogućava redukciju dimenzionalnosti TF-IDF matrice uz očuvanje najvećeg dela informacija sadržanih u tekstu. Kako bi se odredio odgovarajući broj komponenti, analizirana je kumulativna objašnjena varijansa za različite vrednosti parametra `n_components`.

Tabela 8: Objašnjena varijansa nakon TruncatedSVD redukcije

Broj komponenti	Objašnjena varijansa
50	49.85%
100	68.52%
150	80.07%
200	88.64%
250	95.73%
300	100.00%

Može se uočiti da prvih 200 komponenti objašnjava približno 88.6% ukupne varijanse.

Dalje povećavanje broja komponenti dovodi do relativno malog dobitka u količini sačuvanih informacija, uz značajno povećanje dimenzionalnosti.

Zbog toga je izabrano 200 SVD komponenti, koje predstavljaju kompromis između očuvanja informacija i složenosti modela. Nakon spajanja sa numeričkim i kategoričkim atributima formiran je konačan skup podataka dimenzija 123849×425 .

4.6 Transformacija i skaliranje atributa

Nakon kodiranja kategorijskih atributa i redukcije tekstualnih podataka, izvršena je priprema numeričkih atributa za klasterovanje.

Analizom atributa `views`, `employee_count` i `follower_count` uočena je izražena desna asimetrija raspodele. Kako bi se smanjio uticaj ekstremno velikih vrednosti, nad ovim atributima primenjena je logaritamska transformacija:

$$x' = \log(1 + x)$$

Korišćena je funkcija `log1p`, koja omogućava korektnu transformaciju i za vrednosti jednake nuli. Atribut `company_size` nije transformisan jer predstavlja ordinalnu kategoriju, a ne kontinuiranu numeričku veličinu.

Nakon transformacije izvršeno je skaliranje atributa. U konačnom skupu podataka mogu se razlikovati tri grupe obeležja:

- numerički atributi,
- binarni atributi nastali one-hot kodiranjem,
- komponente dobijene TruncatedSVD redukcijom atributa `title`.

Za numeričke attribute i SVD komponente primenjena je standardizacija pomoću metode `StandardScaler`, dok binarni atributi nisu dodatno skalirani kako bi se zadržala njihova prirodna interpretacija.

Nakon sprovedenih transformacija formiran je konačan skup podataka dimenzija 123849×425 , koji je korišćen u svim eksperimentima klasterovanja.

4.7 Redukcija dimenzionalnosti pomoću PCA

Nakon završetka preprocesiranja dobijena je numerička reprezentacija oglasa za posao koja sadrži ukupno 425 atributa. Iako ovakav skup zadržava veliku količinu informacija o poslovima, kompanijama, benefitima i traženim veštinama, njegova visoka dimenzionalnost predstavlja potencijalni problem za algoritme klasterovanja.

U prostorima velike dimenzionalnosti rastojanja između instanci postaju manje informativna, a povećava se i računarska složenost algoritama. Ovaj fenomen u literaturi je poznat kao *prokletstvo dimenzionalnosti* (*curse of dimensionality*). Zbog toga je ispitano da li redukcija dimenzionalnosti može dovesti do stabilnijih i interpretabilnijih klastera.

Za tu svrhu primenjena je analiza glavnih komponenti (PCA – *Principal Component Analysis*). Osnovna ideja PCA metode jeste transformacija originalnog skupa atributa u novi skup međusobno nekorelisanih komponenti koje zadržavaju što veći deo ukupne varijanse podataka.

Za razliku od TruncatedSVD metode, koja je korišćena isključivo za redukciju tekstualne reprezentacije atributa `title`, PCA je primenjena nad kompletnim transformisanim

skupom podataka. Na taj način omogućeno je istovremeno sažimanje informacija sadržanih u numeričkim, kategoričkim i tekstualnim atributima.

Kako bi se procenio stepen redukcije koji je moguće postići bez značajnog gubitka informacija, analizirana je kumulativna objašnjena varijansa za različit broj komponenti. Rezultati su prikazani u tabeli 9.

Tabela 9: Broj PCA komponenti potreban za očuvanje različitog procenta varijanse

Objašnjena varijansa	Broj komponenti
30%	59
50%	101
70%	143
80%	163

Može se primetiti da je za očuvanje čak 70% ukupne varijanse potrebno više od 140 komponenti, dok je za 80% varijanse potrebno više od 160 komponenti. Ovakav rezultat ukazuje na to da informacije u skupu podataka nisu koncentrisane u malom broju dominantnih dimenzija, već su raspoređene kroz veliki broj atributa.

Ipak, cilj PCA redukcije nije isključivo očuvanje maksimalne količine varijanse. U kontekstu klasterovanja često je korisno ispitati i reprezentacije sa manjim brojem komponenti, jer uklanjanje dela šuma i redundantnih informacija može dovesti do jasnije separacije između klastera.

Iz tog razloga formirano je više PCA reprezentacija koje su kasnije korišćene tokom evaluacije algoritama klasterovanja. Pored kompletnog standardizovanog skupa sa 425 atributa, generisane su i reprezentacije koje čuvaju približno 30%, 50%, 70% i 80% ukupne varijanse.

Na ovaj način omogućeno je sistematsko poređenje performansi algoritama na skupovima različite dimenzionalnosti i analiza uticaja redukcije dimenzionalnosti na kvalitet dobijenih klastera.

5 K-Means klasterovanje

5.1 Teorijske osnove algoritma

K-Means predstavlja jedan od najpoznatijih i najčešće korišćenih algoritama klasterovanja. Osnovna ideja algoritma jeste podela skupa podataka na unapred zadat broj klastera tako da instance unutar istog klastera budu što sličnije, dok razlike između različitih klastera budu što veće.

Algoritam funkcioniše iterativno. Na početku se bira broj klastera k , nakon čega se inicijalizuju centri klastera (centroidi). Svaka instanca se zatim dodeljuje najbližem centroidu, nakon čega se centroidi ponovo izračunavaju kao srednja vrednost svih instanci koje pripadaju odgovarajućem klasteru. Postupak se ponavlja sve dok ne dođe do stabilizacije centara ili dok se ne dostigne unapred definisan broj iteracija.

Sum of Squared Errors (SSE)

Cilj K-Means algoritma jeste minimizacija sume kvadrata rastojanja između instanci i centroida klastera kome pripadaju. Ova veličina poznata je kao SSE (*Sum of Squared Errors*) i računa se kao:

$$SSE = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

gde je:

- k broj klastera,
- C_i skup instanci koje pripadaju i -tom klasteru,
- μ_i centroid i -tog klastera.

Manje vrednosti SSE ukazuju na kompaktnije klastere.

Prednost K-Means algoritma ogleda se u njegovoj jednostavnosti, efikasnosti i mogućnosti primene na velikim skupovima podataka. Sa druge strane, algoritam zahteva unapred definisan broj klastera i osetljiv je na izbor početnih centroida i prisustvo autlajera.

5.2 Eksperimentalna postavka

K-Means algoritam primenjen je nad više različitih reprezentacija podataka dobijenih tokom faze preprocesiranja. Cilj eksperimenta bio je da se ispita kako redukcija dimenzionalnosti utiče na kvalitet klasterovanja.

Analizirane su sledeće verzije skupa podataka:

- kompletan standardizovani skup sa 425 atributa,
- PCA reprezentacija koja objašnjava približno 30% varijanse,
- PCA reprezentacija koja objašnjava približno 50% varijanse,
- PCA reprezentacija koja objašnjava približno 70% varijanse,
- PCA reprezentacija koja objašnjava približno 80% varijanse.

Za svaku reprezentaciju ispitane su vrednosti parametra k od 2 do 10. Kao osnovna metrika za evaluaciju korišćen je Silhouette Score.


Pošto skup podataka sadrži više od 120 hiljada oglasa za posao, evaluacija je vršena nad slučajnim uzorkom od 10000 instanci. Na taj način značajno je smanjeno vreme izvršavanja eksperimenata uz očuvanje reprezentativnosti uzorka.

5.3 Izbor broja klastera

Prvi korak u analizi podrazumevao je određivanje odgovarajućeg broja klastera. U tu svrhu primenjena je Elbow metoda.

Kod Elbow metode posmatra se promena SSE metrike (*Sum of Squared Errors*) sa porastom broja klastera. Intuitivno, povećavanje broja klastera dovodi do smanjenja SSE

vrednosti, ali nakon određenog trenutka dodatni klasteri donose sve manje poboljšanje. Tačka u kojoj dolazi do usporavanja pada SSE često se naziva „lakat“ i predstavlja potencijalni izbor optimalnog broja klastera.



Slika 2: Elbow analiza za različite reprezentacije podataka


Na osnovu Elbow metode nije uočen izrazito jasan lakat ni za jednu od posmatranih reprezentacija podataka. Ovakvo ponašanje nije neuobičajeno kod skupova visoke dimenzionalnosti, gde granice između klastera nisu jasno izražene. Zbog toga je kao glavni kriterijum za izbor modela korišćen Silhouette Score.

5.4 Uticaj redukcije dimenzionalnosti

Nakon određivanja opsega vrednosti parametra k , analiziran je uticaj redukcije dimenzionalnosti na kvalitet klasterovanja.

Silhouette Score predstavlja meru koja istovremeno uzima u obzir koheziju unutar klastera i separaciju između različitih klastera. Veće vrednosti ukazuju na jasnije razdvajanje

klastera.



Slika 3: Silhouette Score za različite vrednosti parametra k

Rezultati pokazuju da primena PCA transformacije pozitivno utiče na kvalitet klasterovanja. Dok je kod originalnog skupa podataka prisutan efekat velike dimenzionalnosti, PCA reprezentacije omogućavaju formiranje kompaktnijih i bolje razdvojenih klastera.

Najbolji rezultat među svim analiziranim reprezentacijama ostvaren je nad PCA prostorom najmanje dimenzionalnosti.

5.5 Analiza rezultata i izbor modela


Pošto su prethodni eksperimenti ukazali da PCA može poboljšati kvalitet klasterovanja, sprovedena je dodatna analiza reprezentacija sa veoma malim brojem komponenti.

Razmatrane su PCA reprezentacije sa 3 do 10 komponenti, pri čemu je za svaku reprezentaciju određena optimalna vrednost parametra k na osnovu Silhouette Score metrike.

Tabela 10: Najbolji rezultati za različit broj PCA komponenti

PCA komponente	Objašnjena varijansa	Najbolji k	Silhouette
3	2.69%	4	0.336
4	3.25%	3	0.289
5	3.80%	4	0.263
6	4.34%	5	0.250
7	4.87%	5	0.221
8	5.38%	7	0.208

Rezultati pokazuju da se najbolji modeli ostvaruju za PCA reprezentacije veoma male dimenzionalnosti. Sa povećanjem broja komponenti dolazi do postepenog opadanja vrednosti Silhouette Score metrike, što ukazuje da mali broj glavnih komponenti uspešno zadržava dominantnu strukturu podataka, dok dodatne komponente uglavnom uvode šum koji otežava razdvajanje klastera.



Slika 4: Uticaj broja PCA komponenti na Silhouette Score

Najbolji rezultat ostvaren je za PCA reprezentaciju sa tri glavne komponente i četiri klastera. Dobijena vrednost Silhouette Score iznosila je približno 0.336.

- broj PCA komponenti: 3,
- broj klastera: 4,
- Silhouette Score: 0.336.

Nakon treniranja modela analizirana je raspodela instanci po klasterima.


Tabela 11: Raspodela instanci po klasterima za konačni K-Means model

Klaster	Broj instanci	Udeo (%)
0	4192	41.92
1	2626	26.26
3	1770	17.70
2	1412	14.12

Može se uočiti da su dobijeni klasteri relativno uravnoteženi i da nijedan klaster ne sadrži dominantan deo instanci. Takva raspodela predstavlja poželjnu osobinu i dodatno potvrđuje da izabrani model uspešno identifikuje različite grupe oglasa za posao.

5.6 Vizuelizacija klastera

Radi lakše interpretacije rezultata, klasteri su prikazani u trodimenzionalnom PCA prostoru.



Slika 5: Vizuelizacija klastera dobijenih KMeans algoritmom

Na osnovu vizuelizacije može se uočiti da algoritam uspeva da identifikuje više relativno kompaktnih grupa oglasa. Iako između pojedinih klastera postoji određeni stepen preklapanja, jasno su vidljive oblasti prostora u kojima dominiraju pojedinačne grupe.

6 Agglomerative Clustering

6.1 Teorijske osnove algoritma

Agglomerative Clustering pripada grupi hijerarhijskih algoritama klasterovanja. Za razliku od algoritama zasnovanih na centroidima, kao što je K-Means, hijerarhijski pristup ne polazi od unapred definisanih centara klastera, već gradi hijerarhijsku strukturu podataka kroz postupno spajanje grupa.

Algoritam na početku posmatra svaku instancu kao zaseban klaster. U svakoj iteraciji pronalaze se dva najbližija klastera i spajaju u jednu celinu. Proces se nastavlja sve dok se ne dostigne željeni broj klastera.

Ključna odluka u ovom algoritmu odnosi se na način računanja rastojanja između klastera. U ovom radu analizirane su tri najčešće korišćene strategije povezivanja:

- **Ward linkage** – bira spajanje koje najmanje povećava unutarklastersku varijansu,
- **Complete linkage** – rastojanje između dva klastera definiše se kao najveće rastojanje između njihovih instanci,
- **Average linkage** – koristi prosečno rastojanje između svih parova instanci iz dva klastera.

Prednost hijerarhijskog pristupa jeste mogućnost analize strukture podataka na različitim nivoima granularnosti. Sa druge strane, algoritam je računski zahtevniji od K-Means metode i postaje sporiji na velikim skupovima podataka.

6.2 Eksperimentalna postavka

Eksperimenti su sprovedeni nad istim reprezentacijama podataka koje su korišćene i kod K-Means algoritma. Analizirani su:

- kompletan standardizovani skup sa 425 atributa,
- PCA reprezentacija koja objašnjava približno 30% varijanse,
- PCA reprezentacija koja objašnjava približno 50% varijanse,
- PCA reprezentacija koja objašnjava približno 70% varijanse,
- PCA reprezentacija koja objašnjava približno 80% varijanse.


Za svaku reprezentaciju testirane su Ward, Complete i Average linkage strategije, dok je broj klastera menjan u opsegu od 2 do 10.

Kvalitet modela procenjivan je korišćenjem Silhouette Score metrike opisane u prethodnom poglavlju.

Zbog veličine skupa podataka, evaluacija je vršena nad slučajnim uzorkom od 10000 oglasa za posao.

6.3 Uticaj linkage strategije

Prvi skup eksperimenata imao je za cilj da ispita uticaj različitih linkage strategija na kvalitet klasterovanja.



Slika 6: Silhouette Score za različite linkage strategije i reprezentacije podataka

Rezultati pokazuju da izbor linkage strategije značajno utiče na kvalitet dobijenih klastera. Posebno je zanimljivo da su pojedine konfiguracije Complete linkage metode ostvarivale veoma visoke vrednosti Silhouette Score metrike.

Najveći Silhouette Score u ovoj fazi eksperimenata iznosio je približno 0.390 za PCA reprezentaciju koja objašnjava 30% varijanse i dva klastera.

Međutim, detaljnija analiza raspodele instanci pokazala je da ovakav rezultat ne predstavlja kvalitetno rešenje.

Tabela 12: Raspodela instanci za najbolje rangirani model

Klaster	Broj instanci	Udeo (%)
0	9957	99.57
1	43	0.43

Iako numerička vrednost Silhouette Score metrike sugerše kvalitetno klasterovanje, praktična interpretacija ovakvog rešenja nije zadovoljavajuća. Gotovo sve instance nalaze se u jednom klasteru, dok drugi klaster sadrži zanemarljiv broj oglasa. Zbog toga su u nastavku analizirani samo modeli koji formiraju relativno uravnotežene klastere.

Ovaj primer jasno pokazuje da se kvalitet klasterovanja ne može procenjivati isključivo na osnovu jedne metrike, već je neophodna i analiza raspodele instanci i interpretabilnosti dobijenih grupa.

6.4 Analiza rezultata i izbor modela

Pored originalne eksperimentalne postavke, analizirane su reprezentacije i sa 3 do 10 glavnih komponenti. Za svaku reprezentaciju određena je najbolja kombinacija parametara uz dodatni uslov da najmanji klaster sadrži najmanje 3% instanci.

Tabela 13: Najuspešniji Agglomerative Clustering modeli

PCA	Linkage	k	Silhouette	Najmanji klaster (%)	Najveći klaster (%)
3	ward	6	0.266	7.09	35.95
3	ward	5	0.265	8.84	35.95
3	ward	2	0.263	21.47	78.53
4	ward	4	0.256	10.03	37.58
3	ward	4	0.254	18.76	35.95

Rezultati potvrđuju da se najbolji modeli ostvaruju za PCA reprezentacije veoma male dimenzionalnosti.

Najbolji rezultat ostvaren je za PCA reprezentaciju sa tri glavne komponente i 6 klastera. Veoma slične rezultate ostvarili su i modeli sa pet, četiri i dva klastera, što ukazuje da hijerarhijska struktura podataka nije jednoznačno izražena. Na osnovu kombinacije evaluacionih metrika i raspodele instanci, za dalju analizu izabran je model sa šest klastera.

Kao konačan model izabrana je sledeća konfiguracija:

- broj PCA komponenti: 3,
- linkage strategija: Ward,
- broj klastera: 6,
- Silhouette Score: 0.266.

Raspodela instanci po klasterima prikazana je u tabeli [14](#).


Tabela 14: Raspodela instanci po klasterima za konačni Agglomerative model

Klaster	Udeo (%)
0	35.95
2	18.76
3	16.73
4	12.63
1	8.84
5	7.09

Može se primetiti da nijedan klaster ne dominira skupom podataka i da su sve grupe dovoljno zastupljene da omoguće dalju analizu njihovih karakteristika.

6.5 Vizuelizacija klastera

Radi lakše interpretacije rezultata izvršena je vizuelizacija dobijenih klastera u dvodimenzionalnom i trodimenzionalnom PCA prostoru.




Slika 7: Vizuelizacija klastera dobijenih Agglomerative Clustering algoritmom

Vizuelizacije potvrđuju postojanje više izdvojenih grupa oglasa za posao, ali i određeni stepen preklapanja između pojedinih klastera. Takvo ponašanje očekivano je kod podataka koji opisuju tržište rada, jer različite profesije često dele slične zahteve, nivoe iskustva ili tipove kompanija.

6.6 Analiza dendrograma

Jedna od glavnih prednosti Agglomerative Clustering algoritma jeste mogućnost prikaza hijerarhijske strukture podataka pomoću dendrograma. Dendrogram prikazuje redosled spajanja klastera i rastojanja pri kojima do tih spajanja dolazi.



Slika 8: Dendrogram dobijen Ward metodom nad PCA reprezentacijom sa 3 komponente

Na prikazanom dendrogramu mogu se uočiti veće grupe instanci koje se međusobno spajaju tek na većim vrednostima rastojanja. To ukazuje na postojanje određene strukture u podacima i potvrđuje da oglasi za posao nisu potpuno homogeni. Istovremeno, veliki broj spajanja na manjim rastojanjima sugerise da između pojedinih grupa postoji značajno preklapanje karakteristika.

Posebno je važno primetiti da ne postoji jedna izrazito dominantna tačka preseka koja bi nedvosmisleno odredila optimalan broj klastera. Takvo ponašanje očekivano je kod realnih podataka tržišta rada, gde različite pozicije često dele slične zahteve, nivoe iskustva ili karakteristike kompanija.

Iako dendrogram ne ukazuje na potpuno prirodnu podelu podataka, može se uočiti nekoliko relativno stabilnih grupa koje ostaju razdvojene do većih rastojanja. Ovo potvrđuje da hijerarhijski pristup uspeva da identifikuje određene obrasce u podacima, ali i da granice između pojedinih segmenata tržišta rada nisu strogo definisane.

7 DBSCAN

7.1 Teorijske osnove algoritma

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) predstavlja algoritam klasterovanja zasnovan na gustini podataka. Za razliku od algoritama kao što su K-Means i Agglomerative Clustering, DBSCAN ne zahteva unapred definisan broj klastera, već grupe formira na osnovu lokalne gustine instanci.

Osnovna ideja algoritma jeste da se oblasti velike gustine posmatraju kao klasteri, dok se instance koje ne pripadaju nijednoj gustoj oblasti označavaju kao šum (*noise*).

Rad algoritma određuju dva parametra:

- **eps** – maksimalno rastojanje između dve instance da bi se smatrale susedima,
- **min_samples** – minimalan broj suseda potreban da bi instanca bila proglašena centralnom tačkom klastera.

Za razliku od centroidnih i hijerarhijskih metoda, DBSCAN može identifikovati klaster proizvoljnog oblika i istovremeno vršiti detekciju anomalija. Međutim, kvalitet rezultata značajno zavisi od izbora parametara i strukture podataka.

7.2 Eksperimentalna postavka

DBSCAN je primenjen nad PCA reprezentacijama sa 3 do 10 komponenti. Cilj eksperimenta bio je da se ispita da li u prostoru glavnih komponenti postoje oblasti povećane gustine koje bi odgovarale prirodnim segmentima tržišta rada.

Analizirane su sledeće vrednosti parametara:

- $\text{eps} \in \{0.3, 0.5, 0.7, 1.0, 1.5, 2.0, 2.5, 3.0\}$,
- $\text{min_samples} \in \{5, 10, 20, 50\}$.

Kvalitet modela procenjivan je korišćenjem Silhouette Score metrike, dok je dodatno analiziran procenat instanci označenih kao šum.

Kao i kod prethodnih algoritama, evaluacija je vršena nad slučajnim uzorkom od 10000 oglasa za posao.

7.3 Rezultati eksperimenata

Za svaku PCA reprezentaciju ispitane su različite kombinacije parametara `eps` i `min_samples`. Najbolji rezultati prikazani su u tabeli ??.

Tabela 15: Pet najboljih DBSCAN konfiguracija prema Silhouette Score metrici

PCA	ϵ	MinPts	Broj klastera	Silhouette
3	1.0	50	2	0.408
4	1.5	50	2	0.400
3	0.7	20	2	0.374
4	1.0	5	2	0.366
5	1.5	50	2	0.357

Na prvi pogled rezultati deluju veoma obećavajuće. Najbolja konfiguracija ostvarila je Silhouette Score od približno 0.408.

Međutim, detaljnija analiza pokazala je da ovakve vrednosti ne predstavljaju posledicu kvalitetnog klasterovanja, već specifične raspodele instanci između klastera.

Najbolji DBSCAN model formirao je samo dva klastera, pri čemu je jedan klaster sadržao gotovo sve instance iz skupa podataka.

Raspodela instanci za najbolju konfiguraciju prikazana je u tabeli 16.

Tabela 16: Raspodela instanci za najbolju DBSCAN konfiguraciju


Grupa	Udeo (%)
Klaster 0	97.59
Klaster 1	1.54
Šum	0.87

Može se uočiti da gotovo sve instance pripadaju jednom dominantnom klasteru, dok veoma mali broj oglasa formira zaseban klaster ili biva označen kao šum.

Takva raspodela ukazuje da algoritam nije uspeo da identifikuje više smislenih segmenta tržišta rada. Umesto toga, većina oglasa posmatrana je kao jedna velika homogena grupa, dok su izdvojeni samo retki primeri koji se značajno razlikuju od ostatka podataka.

7.4 Vizuelizacija rezultata

Radi ilustracije ponašanja algoritma, prikazana je vizuelizacija najbolje DBSCAN konfiguracije u PCA prostoru.



Slika 9: Vizuelizacija klastera dobijenih DBSCAN algoritmom

Vizuelizacija potvrđuje da algoritam uglavnom identifikuje jednu dominantnu grupu instanci, dok manji broj oglasa ostaje izdvojen od glavne mase podataka.

Ovakvo ponašanje bliže je problemu detekcije anomalija nego klasičnom segmentisanju tržišta rada.

8 Gaussian Mixture Model (GMM)

8.1 Teorijske osnove algoritma

Gaussian Mixture Model (GMM) predstavlja probabilistički algoritam klasterovanja koji pretpostavlja da su podaci generisani iz mešavine više Gausovih raspodela. Za razliku od K-Means algoritma, gde svaka instanca pripada tačno jednom klasteru, GMM omogućava meko klasterovanje (*soft clustering*), pri čemu se za svaku instancu određuje verovatnoća pripadnosti svakom klasteru.

Gaussian Mixture Model

Osnovna pretpostavka GMM algoritma jeste da su podaci generisani iz mešavine više Gausovih raspodela. Ukupna verovatnoća pojavljivanja instance modeluje se kao:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

gde su:

- K broj komponenti modela,
- π_k težina k -te komponente,
- μ_k vektor srednjih vrednosti,
- Σ_k matrica kovarijanse,
- $\mathcal{N}$ višedimenzionalna normalna raspodela.

Svaka komponenta predstavlja jednu Gausovu raspodelu koja opisuje deo podataka, dok težine π_k određuju koliki doprinos svaka komponenta ima ukupnom modelu.

Parametri GMM modela procenjuju se pomoću Expectation-Maximization (EM) algoritma. Za razliku od K-Means algoritma koji svaku instancu direktno dodeljuje jednom klasteru, EM algoritam polazi od pretpostavke da svaka instanca može pripadati svim klasterima sa određenom verovatnoćom.

EM algoritam sastoji se iz dva koraka koji se iterativno ponavljaju sve do konvergencije modela.

E-korak (Expectation) U prvom koraku za svaku instancu izračunava se verovatnoća pripadnosti svakoj od Gausovih komponenti. Na taj način dobija se tzv. meka dodela klasterima (*soft clustering*), pri čemu instanca ne mora pripadati isključivo jednom klasteru.

M-korak (Maximization) Nakon izračunavanja verovatnoća pripadnosti sledi ažuriranje parametara modela. Ponovo se procenjuju srednje vrednosti komponenti, matrice kovarijanse i njihove težine tako da model što bolje opisuje raspodelu podataka.

Konvergencija algoritma E i M korak smenjuju se kroz više iteracija sve dok promene parametara ne postanu zanemarljive. Kada se dostigne stabilno rešenje smatra se da je algoritam konvergirao.

Zahvaljujući ovakvom pristupu, GMM može da modeluje klasterne različite veličine, gustine i orijentacije, zbog čega je znatno fleksibilniji od K-Means algoritma koji implicitno pretpostavlja klasterne približno sfernog oblika.

Glavna prednost GMM algoritma jeste fleksibilnost i mogućnost modelovanja složenih raspodela. Sa druge strane, algoritam je računski zahtevniji od K-Means-a i može biti osetljiv na inicijalizaciju parametara.

8.2 Eksperimentalna postavka

Kako bi se omogućilo poređenje sa prethodno analiziranim algoritmima, GMM je primenjen nad PCA reprezentacijama sa 3 do 10 glavnih komponenti.

Za svaku PCA reprezentaciju ispitivani su modeli sa brojem komponenti od 2 do 10. Korišćena je puna matrica kovarijanse (`covariance_type="full"`), čime je svakoj komponenti omogućeno da modeluje proizvoljan oblik klastera.

Evaluacija modela vršena je nad slučajnim uzorkom od 10000 instanci korišćenjem sledećih metrika:

- Silhouette Score,
- AIC (*Akaike Information Criterion*),
- BIC (*Bayesian Information Criterion*).

AIC i BIC kriterijumi

AIC i BIC predstavljaju kriterijume za izbor modela koji istovremeno uzimaju u obzir kvalitet prilagođavanja i složenost modela.

$$\begin{aligned}AIC &= 2p - 2 \ln(L) \\BIC &= p \ln(n) - 2 \ln(L)\end{aligned}$$

gde su:

- p broj parametara modela,
- L vrednost funkcije verodostojnosti,
- n broj instanci.

Manje vrednosti AIC i BIC ukazuju na poželjnije modele.

Pored navedenih metrika analizirana je i raspodela instanci po klasterima kako bi se izbegli modeli koji formiraju veoma male ili trivijalne klastere.

8.3 Analiza rezultata i izbor modela

Za svaku PCA reprezentaciju analizirani su modeli sa brojem komponenti od 2 do 10. Evaluacija je vršena pomocu Silhouette Score metrike, kao i AIC i BIC kriterijuma koji uzimaju u obzir složenost modela.

Tabela 17 prikazuje najbolje ostvarene rezultate.

Tabela 17: Najuspešniji GMM modeli

PCA	k	Silhouette	BIC	AIC
3	9	0.254	90170	89529
3	10	0.250	90192	89478
3	4	0.245	91294	91013
3	7	0.244	90867	90369
3	3	0.225	92069	91861

Može se uočiti da svi najbolje rangirani modeli koriste PCA reprezentaciju sa tri komponente. To potvrđuje zaključak dobijen i kod prethodnih algoritama da redukcija dimenzionalnosti značajno doprinosi kvalitetu klasterovanja.

Najveću vrednost Silhouette Score ostvario je model sa devet komponenti ($k = 9$), pri čemu je postignuta vrednost od približno 0.254. Veoma slične rezultate ostvarili su i modeli sa deset, sedam i četiri komponente.

Istovremeno, AIC i BIC kriterijumi pokazuju da povećavanje broja komponenti dovodi do složenijih modela koji ne donose proporcionalno poboljšanje kvaliteta klasterovanja. Zbog toga nije opravdano birati model isključivo na osnovu najveće vrednosti Silhouette metrike.

Iako model sa devet komponenti ostvaruje najbolji rezultat prema svim metrikama, razlika u odnosu na model sa četiri komponente iznosi svega nekoliko stotih delova Silhouette koeficijenta. Sa druge strane, model sa četiri komponente omogućava jednostavniju interpretaciju i lakšu analizu formiranih grupa.


Iz tog razloga za dalju evaluaciju zadržana su oba modela:

- GMM sa 4 komponente,
- GMM sa 9 komponenti.

Model sa devet komponenti predstavlja najbolje rešenje prema evaluacionim metrikama, dok model sa četiri komponente omogućava jednostavnije tumačenje dobijenih klastera. Uporedna analiza ova dva modela omogućiće procenu da li veći broj komponenti zaista donosi korisnije i smislenije grupisanje oglasa za posao.

8.4 Vizuelizacija klastera

Radi lakše interpretacije rezultata izvršena je vizuelizacija klastera u dvodimenzionalnom PCA prostoru.



Slika 10: Vizuelizacija klastera dobijenih GMM algoritmom

Na slici 11 prikazane su vizuelizacije GMM modela sa četiri i devet klastera. Model sa četiri klastera formira veće i lakše interpretabilne grupe, dok model sa devet klastera vrši detaljniju segmentaciju podataka i otkriva dodatne podstrukture među oglasima za posao. Kako je razlika u vrednostima evaluacionih metrika između ova dva modela relativno mala, oba modela zadržana su za dalju analizu. Na taj način moguće je uporediti jednostavniju i pregledniju podelu sa detaljnijom segmentacijom podataka i proceniti koja daje smislenije klasterne.

9 BIRCH klasterovanje

9.1 Teorijske osnove algoritma

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) predstavlja hijerarhijski algoritam klasterovanja razvijen sa ciljem efikasne obrade velikih skupova podataka.

Za razliku od tradicionalnih hijerarhijskih metoda koje zahtevaju računanje velikog broja međusobnih rastojanja između instanci, BIRCH koristi posebnu strukturu podataka poznatu kao CF stablo (*Clustering Feature Tree*). Na taj način omogućena je obrada velikih skupova podataka uz znatno manju memorijsku i računsku složenost.

Osnovna ideja algoritma jeste postepeno sažimanje podataka u skup manjih podklastera koji se kasnije mogu dodatno grupisati u konačne klasterne.

Clustering Feature (CF)

Osnovni gradivni element BIRCH algoritma predstavlja *Clustering Feature* (CF), koji sažeto opisuje podklaster bez potrebe za čuvanjem svih originalnih instanci.

$$CF = (N, LS, SS)$$

gde su:

- N – broj instanci u podklasteru,
- LS (*Linear Sum*) – suma svih instanci:

$$LS = \sum_{i=1}^N x_i$$

- SS (*Squared Sum*) – suma kvadrata svih instanci:

$$SS = \sum_{i=1}^N x_i^2$$

Na osnovu ovih vrednosti moguće je efikasno izračunati centroid, radijus i druge karakteristike podklastera bez potrebe za pristupom originalnim podacima.

Tokom rada algoritma nove instance se postepeno umeću u CF stablo. Ukoliko je instanca dovoljno bliska postojećem podklasteru, ona se pridružuje tom podklasteru. U suprotnom se kreira novi podklaster.

Na taj način algoritam formira hijerarhijsku strukturu koja predstavlja sažetu reprezentaciju originalnog skupa podataka.

Glavna prednost BIRCH algoritma jeste veoma dobra skalabilnost i mogućnost rada nad velikim skupovima podataka. Sa druge strane, kvalitet rezultata u velikoj meri zavisi od izbora parametara koji kontrolišu formiranje podklastera.

9.2 Eksperimentalna postavka

BIRCH algoritam primenjen je nad PCA reprezentacijama sa 3 do 10 glavnih komponenti.

Za svaku PCA reprezentaciju analizirani su modeli sa brojem klastera od 2 do 10. Tokom svih eksperimenata korišćene su sledeće vrednosti parametara:

- $threshold = 0.5$,
- $branching_factor = 50$.

Parametar *threshold* određuje maksimalnu dozvoljenu veličinu podklastera. Manje vrednosti dovode do formiranja većeg broja manjih podklastera, dok veće vrednosti rezultuju grubljim grupisanjem podataka.

Parametar *branching_factor* određuje maksimalan broj čvorova koji se mogu nalaziti u jednom nivou CF stabla. Vrednost 50 predstavlja kompromis između efikasnosti i kvaliteta formiranih podklastera.

Evaluacija modela vršena je pomoću Silhouette Score metrike nad slučajnim uzorkom od 10000 instanci.

9.3 Analiza rezultata i izbor modela

Za svaku PCA reprezentaciju analizirane su različite vrednosti parametra k . Pored Silhouette Score metrike, analizirana je i raspodela instanci po klasterima kako bi se izbegli modeli sa veoma malim grupama.

Tabela 18 prikazuje najbolje ostvarene rezultate.

Tabela 18: Najuspešniji BIRCH modeli

PCA	k	Silhouette	Najmanji klaster (%)	Najveći klaster (%)
3	3	0.298	13.71	46.99
3	4	0.296	10.82	46.99
3	2	0.281	46.99	53.01
6	5	0.215	7.49	46.10
6	9	0.198	4.20	23.60

Rezultati pokazuju da se najbolji modeli ostvaruju za PCA reprezentacije male dimenzionalnosti. Kao i kod prethodno analiziranih algoritama, PCA sa tri komponente pokazala se kao najpogodnija reprezentacija podataka.

Najveći Silhouette Score ostvaren je za model sa tri klastera. Dobijeni klasteri imaju relativno uravnoteženu raspodelu instanci, bez formiranja trivijalnih grupa koje bi sadržale veoma mali broj oglasa. Zbog toga je kao konačan model izabran BIRCH sa tri PCA komponente i tri klastera.

Nakon treniranja konačnog modela analizirana je raspodela instanci po klasterima, prikazana u tabeli 19.


Tabela 19: Raspodela instanci po klasterima za konačni BIRCH model

Klaster	Udeo (%)
0	55.28
1	31.91
2	12.81

Može se uočiti da model nije formirao dominantan klaster koji bi sadržao gotovo sve instance. Najveći klaster obuhvata približno 55% oglasa, dok najmanji sadrži oko 13% instanci. Takva raspodela ukazuje da su identifikovane različite grupe oglasa koje mogu biti predmet dalje analize i interpretacije.

9.4 Vizuelizacija klastera

Radi lakše interpretacije rezultata izvršena je vizuelizacija klastera u PCA prostoru sa tri komponente.



Slika 11: Vizuelizacija klastera dobijenih BIRCH algoritmom

Vizuelna analiza pokazuje da BIRCH formira tri relativno kompaktne grupe instanci koje odgovaraju strukturi uočenoj tokom evaluacije modela. Iako klasteri nisu potpuno razdvojeni, mogu se prepoznati oblasti prostora u kojima dominiraju različite grupe oglasa, što ukazuje na postojanje smislenih obrazaca u podacima.

10 Spectral Clustering

10.1 Teorijske osnove algoritma

Spectral Clustering predstavlja algoritam klasterovanja zasnovan na teoriji grafova. Za razliku od algoritama kao što su K-Means, GMM ili BIRCH, koji klaster formiraju direktno u prostoru atributa, Spectral Clustering najpre konstruiše graf sličnosti između instanci, a zatim vrši klasterovanje u novom prostoru dobijenom spektralnom dekompozicijom tog grafa.

Osnovna ideja algoritma jeste da se složena struktura podataka transformiše u oblik koji omogućava lakše razdvajanje grupa instanci.

Graf sličnosti

Spectral Clustering posmatra skup podataka kao graf u kome:

- čvorovi predstavljaju instance,
- grane povezuju međusobno slične instance,
- težine grana opisuju stepen sličnosti između instanci.

Klasteri se zatim pronalaze analizom strukture grafa umesto direktnim grupisanjem originalnih koordinata podataka.

Nakon formiranja grafa računa se Laplasijan grafa i vrši njegova spektralna dekompozicija. Sopstveni vektori koji odgovaraju najmanjim sopstvenim vrednostima koriste se za

formiranje nove reprezentacije podataka u kojoj su potencijalni klasteri jasnije izraženi.

U završnom koraku nad novim koordinatama primenjuje se algoritam K-Means koji formira konačne klastere.

Glavna prednost Spectral Clustering algoritma jeste mogućnost otkrivanja klastera složenog oblika koji ne moraju biti sferni niti linearno razdvojivi. Sa druge strane, algoritam je računski zahtevan jer zahteva konstrukciju i obradu matrice sličnosti između instanci.

10.2 Eksperimentalna postavka

Kako bi se omogućilo poređenje sa prethodno analiziranim algoritmima, Spectral Clustering primenjen je nad PCA reprezentacijama sa 3 do 10 glavnih komponenti.

Zbog visoke računске složenosti algoritma korišćen je slučajni uzorak od 5000 instanci. Na taj način omogućeno je izvođenje eksperimenata uz prihvatljivo vreme izvršavanja i potrošnju memorije.

Tokom eksperimenata korišćena je konfiguracija:

- `affinity = nearest_neighbors`,
- `n_neighbors = 10`,
- `assign_labels = kmeans`.

Za svaku PCA reprezentaciju analizirani su modeli sa brojem klastera od 2 do 10.

Kao osnovna metrika za evaluaciju korišćen je Silhouette Score, dok je dodatno analizirana i raspodela instanci po klasterima kako bi se izbegla trivijalna rešenja sa veoma malim grupama.

10.3 Analiza rezultata i izbor modela

Za svaku PCA reprezentaciju analizirane su različite vrednosti parametra k . Rezultati pokazuju da se najbolje performanse ostvaruju za reprezentacije male dimenzionalnosti.

Tabela 20: Najuspešniji Spectral Clustering modeli

PCA	k	Silhouette	Najmanji klaster (%)	Najveći klaster (%)
3	2	0.315	48.60	51.40
3	4	0.307	18.40	32.26
4	4	0.273	11.26	37.08
4	3	0.267	14.62	45.40
3	5	0.264	14.70	23.42


Može se uočiti da najbolje rangirani modeli koriste PCA reprezentaciju sa tri komponente, što je u skladu sa rezultatima prethodno analiziranih algoritama.

Najveći Silhouette Score ostvaren je za model sa dva klastera, pri čemu je postignuta vrednost od približno 0.315. Dobijeni klasteri bili su gotovo potpuno uravnoteženi, sa približno jednakim brojem instanci u obe grupe.

Iako model sa četiri klastera ostvaruje veoma sličan rezultat, model sa dva klastera pruža jednostavniju interpretaciju i jasnije razdvajanje dominantnih grupa prisutnih u podacima. Kako su složenije segmentacije već analizirane kroz druge algoritme klasterovanja, za konačan Spectral Clustering model odabrana je podela na dva klastera.

10.4 Vizuelizacija klastera

Radi lakše interpretacije rezultata izvršena je vizuelizacija klastera u dvodimenzionalnom PCA prostoru.



Slika 12: Vizuelizacija klastera dobijenih Spectral Clustering algoritmom

Na slici su prikazane vizuelizacije dva najznačajnija Spectral Clustering modela. Leva slika prikazuje podelu na dva klastera, dok desna prikazuje podelu na četiri klastera.

Kod modela sa dva klastera može se uočiti jasna podela prostora na dve velike grupe instanci. Ovakva struktura ukazuje da algoritam uspešno identifikuje dominantnu podelu prisutnu u podacima, što je potvrđeno i najvećom vrednošću Silhouette Score metrike.

Model sa četiri klastera vrši detaljniju segmentaciju prostora i otkriva dodatne podgrupe koje nisu vidljive kod jednostavnije podele. Iako su granice između pojedinih klastera manje izražene, mogu se prepoznati različiti regioni prostora u kojima dominiraju pojedine grupe oglasa.

Vizuelna analiza potvrđuje da povećanje broja klastera omogućava otkrivanje finije strukture podataka, ali istovremeno dovodi do složenije interpretacije rezultata.

11 Evaluacija i interpretacija rezultata

Nakon sprovedenih eksperimenata neophodno je odrediti koji model najuspešnije opisuje strukturu analiziranih podataka. Za razliku od nadgledanog učenja, kod klasterovanja ne postoje unapred poznate klase koje bi omogućile direktno merenje tačnosti modela, zbog čega je evaluacija zasnovana na kombinaciji internih metrika i interpretacije dobijenih klastera.

Prvi korak predstavlja poređenje modela korišćenjem Silhouette Score metrike i analize raspodele instanci po klasterima. Međutim, izbor konačnog modela nije zasnovan

isključivo na ovim pokazateljima. Dodatno su analizirani atributi koji nisu korišćeni tokom klasterovanja, uključujući plate, nazive radnih pozicija, veštine, industrije i veličinu kompanija.

Cilj evaluacije bio je da se identifikuje model koji, pored dobrih vrednosti internih metrika, formira stabilne, interpretabilne i poslovno relevantne klastere.

11.1 Uporedna analiza internih metrika

Nakon sprovedenih eksperimenata izvršeno je poređenje najuspešnijih konfiguracija svakog algoritma klasterovanja. Kao osnovna interna metrika korišćen je Silhouette Score, koji istovremeno uzima u obzir kompaktnost klastera i njihovu međusobnu razdvojenost.

Pored vrednosti Silhouette Score analizirana je i raspodela instanci po klasterima. Ovaj korak je važan jer visoka vrednost evaluacione metrike ne mora nužno ukazivati na kvalitetno klasterovanje. U pojedinim slučajevima model može formirati veoma neuravnotežene klastere ili izdvojiti samo mali broj instanci u zasebne grupe, što otežava interpretaciju rezultata.

Tabela 21: Poređenje najboljih modela klasterovanja

Model	PCA	k	Silhouette	Evaluacija
K-Means	3	4	0.336	ceo skup
Spectral Clustering	3	2	0.315	uzorak 5000
BIRCH	3	3	0.298	ceo skup
Agglomerative	3	6	0.266	uzorak 10000
GMM (k=9)	3	9	0.254	ceo skup
GMM (k=4)	3	4	0.245	ceo skup

Na osnovu rezultata prikazanih u tabeli 21 može se uočiti da svi najuspešniji modeli koriste PCA reprezentaciju sa tri komponente. Ovakav rezultat potvrđuje zaključak izveden tokom prethodnih eksperimenata da mali broj glavnih komponenti uspešno zadržava dominantnu strukturu podataka i istovremeno uklanja deo šuma prisutnog u originalnom prostoru atributa.

Najveću vrednost Silhouette Score ostvario je K-Means model sa četiri klastera, dok je drugo mesto zauzeo Spectral Clustering sa dva klastera. Veoma konkurentne rezultate ostvario je i BIRCH, dok su GMM i Agglomerative Clustering postigli nešto niže vrednosti metrike.

Međutim, vrednosti Silhouette Score ne predstavljaju jedini kriterijum za izbor konačnog modela. Pored kvaliteta razdvajanja klastera neophodno je analizirati i njihovu interpretabilnost, kao i povezanost sa atributima koji nisu korišćeni tokom klasterovanja. Zbog toga su svi prikazani modeli uključeni u narednu fazu evaluacije.

11.2 Interpretacija klastera na osnovu naziva radnih pozicija

Kako bi se procenila interpretabilnost dobijenih klastera, analizirani su najzastupljeniji nazivi radnih pozicija unutar svakog klastera. Za razliku od internih metrika, ovakav pristup omogućava direktan uvid u to da li formirane grupe odgovaraju intuitivnim segmentima tržišta rada.

Ova analiza sprovedena je za modele koji su trenirani nad kompletnim skupom podataka. Zbog toga Spectral Clustering i Agglomerative Clustering nisu uključeni u ovaj deo evaluacije, budući da su zbog računskih ograničenja trenirani nad uzorcima od 5000, odnosno 10000 instanci.

11.2.1 K-Means

Tabela 22 prikazuje dominantne tipove zanimanja identifikovane unutar K-Means klastera.

Tabela 22: Dominantni tipovi zanimanja po K-Means klasterima

Klaster	Dominantna zanimanja	Interpretacija
0	Customer Service Representative, Receptionist, Registered Nurse, Patient Care Technician, Service Technician	Korisnička podrška i operativni poslovi
1	Administrative Assistant, Staff Accountant, Associate Attorney, Executive Assistant, Physical Therapist	Administracija, finansije i stručne službe
2	Sales Manager, Project Manager, Store Manager, Account Manager, Business Development Manager	Prodaja i menadžment
3	Software Engineer, Data Analyst, Data Engineer, Business Analyst, Electrical Engineer	IT i inženjering

Može se uočiti da svaki klaster odgovara jasno prepoznatljivom segmentu tržišta rada. Posebno se izdvajaju klasteri prodaje i menadžmenta, kao i IT i inženjerskih zanimanja, dok preostala dva klastera okupljaju administrativne i operativne poslove. Ovakva struktura ukazuje da K-Means formira tematski veoma homogene grupe koje je lako interpretirati.

11.2.2 GMM sa četiri komponente

Analiza GMM modela sa četiri komponente pokazuje veoma sličnu strukturu klastera.

Tabela 23: Dominantni tipovi zanimanja po GMM-4 klasterima

Klaster	Dominantna zanimanja	Interpretacija
0	Software Engineer, Data Analyst, Data Engineer, Electrical Engineer, Mechanical Engineer	IT i inženjering
1	Senior Accountant, Administrative Assistant, Associate Attorney, Controller, Mortgage Loan Officer	Administracija, finansije i pravni poslovi
2	Customer Service Representative, Receptionist, Patient Care Technician, Service Technician, Registered Nurse	Korisnička podrška i operativni poslovi
3	Sales Manager, Project Manager, Account Executive, Account Manager, Store Manager	Prodaja i menadžment

Dobijeni rezultati potvrđuju stabilnost strukture uočene kod K-Means modela. Iako su granice između pojedinih grupa definisane drugačijim probabilističkim pristupom, dominantni tipovi zanimanja ostaju gotovo identični.

11.2.3 GMM sa devet komponenti

Za razliku od modela sa četiri komponente, GMM sa devet komponenti vrši dodatnu segmentaciju prethodno identifikovanih grupa.

Tabela 24: Primeri specijalizovanih klastera identifikovanih GMM-9 modelom

Klaster	Dominantna zanimanja
Menadžerske pozicije	Sales Manager, District Manager, Merchandise Manager
Retail menadžment	Store Manager, Assistant Store Manager, Retail Sales Associate
Zdravstvo	Registered Nurse, Physical Therapist, Nurse Practitioner
IT i analitika	Software Engineer, Data Engineer, Data Analyst

Za razliku od GMM modela sa četiri komponente, model sa devet komponenti formira veći broj manjih i specijalizovanih klastera. Zbog toga pojedinačni klasteri više ne predstavljaju široke segmente tržišta rada, već izdvajaju uže grupe zanimanja sa sličnim karakteristikama.

Tabela 24 prikazuje nekoliko reprezentativnih primera takvih klastera. Može se uočiti da model uspešno identifikuje zasebne grupe menadžerskih pozicija, maloprodajnih po-

slova, zdravstvenih zanimanja i IT profesija. Ovakva segmentacija nije bila toliko izražena kod modela sa četiri komponente, gde su se pojedine od ovih grupa nalazile unutar istog klastera.

Istovremeno, analiza pokazuje da pojedina zanimanja mogu biti prisutna u više klastera. Takvo ponašanje je očekivano jer naziv radne pozicije nije jedina informacija korišćena tokom klasterovanja. Pored atributa `title`, modeli uzimaju u obzir i veštine, benefite, veličinu kompanije i druge karakteristike oglasa, zbog čega se oglasi sa istim nazivom pozicije mogu naći u različitim klasterima.

Dobijeni rezultati ukazuju da GMM sa devet komponenti otkriva finiju unutrašnju strukturu podataka, ali po cenu složenije interpretacije. Nasuprot tome, model sa četiri komponente formira preglednije i lakše razumljive grupe zanimanja..

11.2.4 BIRCH

Rezultati dobijeni BIRCH algoritmom pokazuju znatno slabiju homogenost klastera.

Tabela 25: Dominantna zanimanja po BIRCH klasterima

Klaster	Dominantna zanimanja
0	Sales Manager, Customer Service Representative, Project Manager, Registered Nurse, Receptionist, Staff Accountant
1	Store Manager, Assistant Store Manager, Retail Sales Associate, Sales Associate
2	Software Engineer, Data Analyst, Business Analyst, Data Engineer, Electrical Engineer


Za razliku od K-Means i GMM modela, prvi BIRCH klaster istovremeno sadrži zanimanja iz oblasti prodaje, administracije, zdravstva i tehničkih poslova. Takva struktura otežava interpretaciju rezultata i ukazuje na slabiju homogenost formiranih grupa.

Analiza naziva radnih pozicija pokazuje da K-Means i GMM formiraju najjasnije i najinterpretabilnije klastere. GMM sa devet komponenti dodatno otkriva finiju unutrašnju strukturu podataka, dok BIRCH pokazuje veću tendenciju ka mešanju različitih tipova zanimanja unutar istog klastera.

11.3 Analiza plata po klasterima

Kako informacije o platama nisu korišćene tokom procesa klasterovanja, one predstavljaju nezavisan kriterijum za procenu kvaliteta dobijenih klastera. Ukoliko model uspe da formira grupe koje se značajno razlikuju po visini zarade, može se zaključiti da je identifikovana stvarna struktura tržišta rada, a ne samo matematička podela podataka.

Za svaki model izračunata je medijalna vrednost normalizovane plate unutar svakog klastera. Medijana je korišćena umesto aritmetičke sredine zbog prisustva ekstremno visokih plata koje mogu značajno uticati na prosečne vrednosti.




Slika 13: Medijalne plate po klasterima za analizirane modele

Na slici 13 prikazane su medijalne plate za sve klasterne dobijene različitim algoritmima. Može se uočiti da svi modeli uspevaju da izdvoje grupe poslova različitog nivoa zarade, što predstavlja pozitivan pokazatelj kvaliteta klasterovanja. Međutim, između modela postoje značajne razlike u stepenu i načinu na koji je ova segmentacija ostvarena.

K-Means model pokazuje najjasniju i najstabilniju strukturu. Medijalne plate rastu od približno 66 hiljada dolara u prvom klasteru do približno 110 hiljada dolara u četvrtom klasteru. Dobijeni klasteri mogu se posmatrati kao prirodna podela poslova na niže, srednje i više plaćene pozicije. Posebno je značajno što je ovakva segmentacija postignuta bez korišćenja informacija o platama tokom samog procesa klasterovanja.

BIRCH model takođe uspeva da formira klasterne sa jasno različitim nivoima zarade. Medijalne vrednosti rastu od približno 68 hiljada do 108 hiljada dolara, što ukazuje da algoritam prepoznaje određenu hijerarhiju poslova. Međutim, analiza naziva radnih pozicija pokazala je da se unutar istih klastera često nalaze veoma različita zanimanja, zbog čega interpretacija dobijenih grupa ostaje ograničena.

Kod GMM modela sa četiri komponente uočavaju se značajne razlike između klastera, pri čemu se medijalne plate kreću od približno 57 hiljada do 105 hiljada dolara. Model sa devet komponenti ostvaruje još detaljniju segmentaciju i identifikuje klasterne čije se medijalne plate kreću od približno 52 hiljade do gotovo 118 hiljada dolara. Iako ovakav pristup omogućava preciznije razlikovanje pojedinih grupa poslova, povećava se broj klastera sa međusobno sličnim karakteristikama, što otežava interpretaciju rezultata.



Slika 14: Raspodela plata po klasterima za Agglomerative i Spectral Clustering modele

Agglomerative Clustering pokazuje slabije rezultate u poredenju sa prethodnim modelima. Medijalne plate između klastera ne formiraju jasan obrazac, već značajno osciluju između različitih grupa. Dodatna analiza naziva pozicija pokazuje da su dobijeni klasteri veoma heterogeni i da okupljaju poslove različitih profila, što ukazuje na slabiju interpretabilnost modela.


Slično tome, Spectral Clustering formira samo dva velika klastera sa medijalnim platama od približno 63 i 81 hiljadu dolara. Iako postoji razlika između grupa, mali broj klastera ograničava mogućnost detaljnije segmentacije tržišta rada.

Zaključak: Posmatrajući rezultate svih modela može se zaključiti da je K-Means ostvario najbolji balans između kvaliteta segmentacije i interpretabilnosti dobijenih klastera. Njegovi klasteri pokazuju jasne razlike u nivou zarade, dok istovremeno zadržavaju prepoznatljivu strukturu zanimanja. Ovakav rezultat predstavlja snažan pokazatelj da je model uspešno identifikovao stvarne obrasce prisutne na tržištu rada, zbog čega je izabran kao konačno rešenje za dalju analizu.

11.4 Interpretacija klastera

Pored analize internih metrika i raspodele plata, dodatna evaluacija modela sprovedena je analizom karakteristika koje dominiraju u svakom klasteru. Posebna pažnja posvećena je nazivima radnih pozicija, veštinama i industrijama kako bi se utvrdilo da li formirani klasteri odgovaraju intuitivnim segmentima tržišta rada.

Za detaljniju interpretaciju korišćen je K-Means model, koji je ostvario najbolje rezultate tokom prethodnih eksperimenata. Na slici 15 prikazana je raspodela najzastupljenijih veština po klasterima.



Slika 15: Najzastupljenije veštine po K-Means klasterima

Može se uočiti da svaki klaster poseduje karakterističan profil veština. Takva struktura predstavlja važan pokazatelj kvaliteta klasterovanja, jer ukazuje da algoritam nije grupisao oglase slučajno, već je izdvojio grupe sa različitim profesionalnim karakteristikama.

Klaster 0 – Operativni poslovi velikih kompanija Klaster 0 karakterišu pozicije iz oblasti korisničke podrške, maloprodaje, logistike i administrativnih poslova. Dominiraju nazivi poput *Customer Service Representative*, *Receptionist* i *Retail Sales Associate*. Oglasi iz ovog segmenta najčešće potiču iz velikih kompanija, dok su najzastupljenije industrije zdravstvo, maloprodaja i finansijske usluge. Profil veština pokazuje kombinaciju menadžerskih, proizvodnih i administrativnih kompetencija bez izražene specijalizacije. Ovaj klaster ostvaruje najniže medijane plata u okviru K-Means modela i može se posmatrati kao grupa operativnih i podržavajućih poslovnih funkcija.

Klaster 1 – Zdravstvene i profesionalne usluge Klaster 1 okuplja zdravstvene i profesionalne pozicije, uključujući *Registered Nurse*, *Physical Therapist*, *Licensed Therapist* i srodna zanimanja. Industrijska analiza pokazuje veliku zastupljenost sektora zdravstva, dok profil veština karakteriše dominantno prisustvo zdravstvenih kompetencija. Poslovi iz ovog segmenta najčešće dolaze iz malih i srednjih kompanija. Medijane plata više su nego u operativnom segmentu, ali i dalje niže od tehničkih i menadžerskih klastera. Ovaj segment predstavlja specijalizovane profesionalne usluge sa naglašenom orijentacijom ka zdravstvenom sektoru.

Klaster 2 – Menadžment, prodaja i poslovni razvoj Klaster 2 jasno predstavlja poslovni i prodajni segment tržišta rada. Dominiraju pozicije kao što su *Sales Manager*, *Project Manager*, *Account Manager*, *Store Manager* i *Business Development Manager*. Veštine iz oblasti prodaje, poslovnog razvoja i upravljanja značajno se izdvajaju u odnosu na ostale klastere, dok industrijska analiza pokazuje veliku zastupljenost maloprodaje i komercijalnih delatnosti. Kompanije su uglavnom srednje i velike, a medijane plata među najvišima su u okviru modela. Ovaj klaster predstavlja grupu poslova povezanih sa upravljanjem, prodajom i razvojem poslovanja.

Klaster 3 – Tehnički i analitički poslovi Klaster 3 predstavlja najjasnije definisan segment tržišta rada. Dominiraju pozicije *Software Engineer*, *Senior Software Engineer*, *Data Engineer*, *Data Analyst* i *Business Analyst*. Najzastupljenije industrije su *IT Services and IT Consulting* i *Software Development*, dok profil veština pokazuje izrazitu dominaciju IT i inženjerskih kompetencija. Ovaj klaster ostvaruje i najviše medijane plata u okviru K-Means modela, što dodatno potvrđuje da predstavlja segment visokokvalifikovanih tehničkih i analitičkih zanimanja.

Analiza industrija daje dodatnu potvrdu ovakve podele. Tehnološke kompanije i poslovi razvoja softvera dominantno su prisutni u tehničkom klasteru, dok se poslovi prodaje i menadžmenta grupišu u zaseban segment. Slično tome, administrativne i finansijske pozicije formiraju relativno homogenu grupu, dok su poslovi korisničke podrške i zdravstva koncentrisani u posebnom klasteru.

Dobijeni rezultati pokazuju da K-Means uspešno identifikuje prirodne segmente tržišta rada. Formirani klasteri nisu definisani isključivo na osnovu matematičke sličnosti instanci, već odgovaraju grupama zanimanja koje imaju jasno poslovno značenje i koje se razlikuju prema veštinama, industrijama i platama.

11.5 Uticaj atributa `title` na kvalitet klasterovanja

Tokom razvoja modela postavljeno je pitanje da li veliki broj atributa dobijenih obradom naziva radnih pozicija zaista doprinosi kvalitetu klasterovanja ili predstavlja nepotrebno povećanje dimenzionalnosti skupa podataka. Zbog toga je sproveden dodatni eksperiment u kome je K-Means algoritam treniran nad skupom podataka iz kojeg su uklonjene sve SVD komponente izvedene iz atributa `title`.

Tabela 26 prikazuje poređenje najboljih modela sa i bez uključivanja atributa `title`.

Tabela 26: Poređenje K-Means modela sa i bez atributa `title`

Model	PCA	k	Silhouette
K-Means sa <code>title</code>	3	4	0.336
K-Means bez <code>title</code>	3	3	0.409

Na prvi pogled moglo bi se zaključiti da je model bez atributa `title` kvalitetniji, budući da ostvaruje značajno višu vrednost Silhouette Score metrike. Međutim, detaljna analiza sadržaja klastera pokazuje da takav zaključak nije opravdan.

Tabela 27 prikazuje dominantne nazive pozicija za klastere dobijene modelom bez atributa `title`.

Tabela 27: Dominantne pozicije kod modela bez atributa `title`

Klaster	Dominantne pozicije
0	Sales Manager, Project Manager, Customer Service Representative, Executive Assistant, Senior Accountant, Registered Nurse
1	Software Engineer, Data Analyst, Business Analyst, Administrative Assistant, Senior Accountant, Account Executive
2	Customer Service Representative, Retail Sales Associate, Receptionist, Store Manager, Registered Nurse

Može se primetiti da se unutar istih klastera pojavljuju pozicije iz potpuno različitih profesionalnih oblasti. U prvom klasteru istovremeno se nalaze prodajne, administrativne, finansijske i zdravstvene pozicije. Slična situacija prisutna je i kod preostalih klastera, gde su tehničke, poslovne i administrativne uloge objedinjene u iste grupe.

Dodatna analiza atributa *formatted_work_type*, *application_type* i *formatted_experience_level* pokazala je da model bez atributa **title** ne ostvaruje značajno bolje razdvajanje ni po ovim karakteristikama. Klasteri oba modela imaju veoma slične profile u pogledu tipa zaposlenja, načina prijave i nivoa iskustva.

Posebno je značajno da ni analiza plata ne pruža prednost modelu bez atributa **title**.

Tabela 28: Medijalne plate po klasterima

Model	Klaster	Medijalna plata
K-Means sa title	0	66 560
	1	72 083
	2	100 000
	3	110 000
K-Means bez title	0	75 000
	1	80 060
	2	101 500

Može se uočiti da oba modela uspevaju da izdvoje grupe sa različitim nivoima zarada, što potvrđuje da plata predstavlja relevantan indikator strukture tržišta rada iako nije korišćena tokom klasterovanja.

Ipak, model koji uključuje atribut **title** formira četiri jasno razdvojena nivoa plata, od približno 66 hiljada do 110 hiljada dolara. Nasuprot tome, model bez atributa **title** formira samo tri grupe sa manjim razlikama između medijana plata.

Kada se ovi rezultati posmatraju zajedno sa analizom dominantnih naziva pozicija, može se zaključiti da model sa atributom **title** ne samo da uspešnije razdvaja profesionalne profile, već istovremeno identifikuje i jasnije platne segmente tržišta rada.

Ovaj eksperiment pokazuje da viša vrednost interne metrike ne mora nužno značiti i kvalitetnije klasterovanje. Iako model bez atributa **title** ostvaruje bolji Silhouette Score, dobijeni klasteri nemaju jasno poslovno značenje. Zbog toga je kao konačno rešenje izabran model koji uključuje atribut **title**, jer formira znatno interpretabilnije i smislenije segmente tržišta rada.

12 Zaključak

U okviru ovog rada izvršena je analiza skupa podataka LinkedIn Job Postings sa ciljem identifikacije prirodnih segmenata tržišta rada primenom tehnika nenadgledanog učenja. Nakon detaljnog procesa pripreme podataka formirana je jedinstvena reprezentacija oglasa koja kombinuje numeričke, kategoričke i tekstualne informacije. Posebna pažnja posvećena je obradi atributa *title*, čime su u analizu uključene semantičke informacije sadržane u nazivima radnih pozicija.

Tokom eksperimentalnog dela rada analizirano je više različitih algoritama klasterovanja, uključujući K-Means, Gaussian Mixture Models, BIRCH, Agglomerative Clustering, Spectral Clustering i DBSCAN. Poređenje modela pokazalo je da interne metrike same po

sebi nisu dovoljne za izbor najboljeg rešenja. Iako su pojedini modeli ostvarivali slične ili čak bolje vrednosti Silhouette Score metrike, detaljna analiza sadržaja klastera pokazala je značajne razlike u njihovoj interpretabilnosti.

Najbolje rezultate ostvario je K-Means model sa četiri klastera treniran nad PCA reprezentacijom sa tri komponente. Dobijeni klasteri pokazali su jasne razlike u pogledu dominantnih zanimanja, traženih veština, industrija, veličine kompanija i nivoa zarada. Posebno je značajno što informacije o platama nisu korišćene tokom procesa klasterovanja, a ipak su identifikovani klasteri sa jasno različitim medijanama plata. Ovakav rezultat predstavlja snažnu potvrdu da model uspešno otkriva stvarnu strukturu tržišta rada.

Dodatni eksperimenti pokazali su da uklanjanje atributa *title* dovodi do povećanja vrednosti Silhouette Score metrike, ali istovremeno rezultuje formiranjem znatno manje interpretabilnih klastera. Time je potvrđeno da viša vrednost interne metrike ne mora nužno značiti i kvalitetnije klasterovanje, kao i da izbor modela treba zasnivati na kombinaciji kvantitativne evaluacije i domenskog razumevanja problema.

Rezultati rada ukazuju da se tržište rada može uspešno segmentirati na osnovu karakteristika oglasa za posao, pri čemu naziv radne pozicije predstavlja jedan od najvažnijih izvora informacija. Dobijeni klasteri mogu poslužiti kao osnova za dalje analize tržišta rada, razvoj sistema za preporuku poslova, praćenje trendova zapošljavanja i detaljnije proučavanje odnosa između zanimanja, veština i nivoa zarada.

Literatura

- [1] Arsh Kononov, *LinkedIn Job Postings Dataset*, Kaggle. Dostupno na: <https://www.kaggle.com/datasets/arshkon/linkedin-job-postings>
- [2] Matematički fakultet Univerziteta u Beogradu, *Priprema podataka*, Dostupno na: <https://www.istranzivanjepodataka.matf.bg.ac.rs/ip2/ip2.materijali/ip.priprema.podataka.html>
- [3] Matematički fakultet Univerziteta u Beogradu, *Klasterovanje*, Dostupno na: <https://www.istranzivanjepodataka.matf.bg.ac.rs/ip2/ip2.materijali/ip2.klasterovanje.html>
- [4] Nenad Mitić, *Algoritmi klasterovanja*, Matematički fakultet Univerziteta u Beogradu. Dostupno na: https://poincare.matf.bg.ac.rs/~nenad/ip1/14.algoritmi_klasterovanja.pdf
- [5] Nenad Mitić, *Uvod u klaster analizu*, Matematički fakultet Univerziteta u Beogradu. Dostupno na: https://poincare.matf.bg.ac.rs/~nenad/ip1/13.uvod_u_klaster_analizu.pdf
- [6] Nenad Mitić, *Priprema podataka*, Matematički fakultet Univerziteta u Beogradu. Dostupno na: https://poincare.matf.bg.ac.rs/~nenad/ip1/3.Priprema_podataka.pdf
- [7] Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar, *Introduction to Data Mining*, 2nd Edition, Pearson Education, 2019.